ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

ΤΜΗΜΑ ΜΑΘΗΜΑΤΙΚΩΝ

ΠΜΣ «ΥΠΟΛΟΓΙΣΤΙΚΗ ΚΑΙ ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ ΕΠΙΣΤΗΜΗ ΤΩΝ ΔΕΔΟΜΕΝΩΝ (MCDA)»

ΜΑΘΗΜΑ:ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

ΑΣΚΗΣΗ: ΑΞΙΟΛΟΓΗΣΗ ΑΛΓΟΡΙΘΜΩΝ ΠΑΛΙΝΔΡΟΜΗΣΗΣ ΣΕ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ UCI

Περιεχόμενα

Εισαγωγή 3
Περιγραφή του data set 3
1.Κατανόηση και αρχική διερεύνηση των δεδομένων 3
Προεπεξεργασία 8
2.Προεπεξεργασία των δεδομένων 8
Μοντέλα και μετρικές αξιολόγησης 9
3. Δημιουργία Baseline Μοντέλων 9
4. Διασταυρούμενη επικύρωση 10
Επιλογή μεταβλητών 12
5. Επιλογή Μεταβλητών (feature selection) 12
Βελτιστοποίηση Υπερπαραμέτρων 13
6.Ρύθμιση υπερπαραμέτρων (hyperparameter tuning) 13
7. Ανάλυση Σφαλμάτων και διαγνωστικοί έλεγχοι 15
Ερμηνευσιμότητα και SHAP analysis 17
8. Ερμηνευσιμότητα Μοντέλου 17
Συζήτηση αποτελεσμάτων και Συμπεράσματα 20
9.Σύγκριση απλών και σύνθετων μοντέλων 20
10. Αναπαραγωγιμότητα και πειραματικός σχεδιασμός 21

Εισαγωγή

Αντικείμενο της παρούσας εργασίας είναι η ανάπτυξη, σύγκριση και ερμηνεία μοντέλων παλινδρόμησης πάνω σε πραγματικά δεδομένα. Παρακάτω παρουσιάζεται μια ολοκληρωμένη εργασία πάνω σε πραγματικά δεδομένα που ξεκινά από την κατανόηση των δεδομένων και των παραμέτρων και καταλήγει στην αξιολόγηση αλγορίθμων και στην βελτίωση αυτών.

Περιγραφή του data set

1.Κατανόηση και αρχική διερεύνηση των δεδομένων

1.1 Περιγραφή του προβλήματος παλινδρόμησης

Για τους σκοπούς της εργασίας, η ανάλυση μας βασίστηκε σε δεδομένα από το 'UCI Machine Learning Repository' και το data set που αξιοποιήθηκε ως πηγή δεδομένων και πληροφόρησης είναι το 'Real Estate Valuation' (https://archive.ics.uci.edu/dataset/477/real+estate+valuation+data+set). Το συγκεκριμένο πρόβλημα αφορά την πρόβλεψη της εμπορικής αξίας ακινήτων στην περιοχή Sindian της Ταϊβάν. Στόχος είναι η αξιολόγηση διαφορετικών μοντέλων και η δημιουργία τελικά ενός μοντέλου που θα μπορεί να υπολογίζει την τιμή ανά τετραγωνικό μονάδα, λαμβάνοντας υπόψιν διαφορετικές μεταβλητές εισόδου. Η επίλυση αυτού του προβλήματος επιτρέπει τη αυτοματοποίηση και ενδεχομένως την πιο αντικειμενική αξιολόγηση της αξίας των ακινήτων.

1.2 Χαρακτηριστικά εισόδου και μεταβλητή στόχος

Το 'Real Estate Valuation' data set αποτελείται επί της ουσίας από 6 μεταβλητές εισόδου (features) και από μια μεταβλητή στόχο. Οι μεταβλητές εισόδου είναι οι εξής:

- X1 transaction date: Η χρονική στιγμή κατά την οποία έγινε η πώληση. Η ημερομηνία δίνεται σε δεκαδική μορφή, με το ακέραιο μέρος να αναπαριστά τον μήνα και το δεκαδικό το ποσοστό του έτους που έχει μεσολαβήσει.
- X2 house age: Η ηλικία του ακινήτου (τα έτη που έχουν μεσολαβήσει από την κατασκευή του).
- X3 distance to the nearest MRT station: Η απόσταση από το κοντινότερο σταθμό Μετρό
- X4 number of convenience stores: Αριθμός καταστημάτων που υπάρχουν στην γειτονία κοντά στο σπίτι.
- X5 latitude: Γεωγραφικό πλάτος.
- X6 longitude: Γεωγραφικό μήκος.

Και η μεταβλητή στόχος, της οποίας την μελέτη θέλουμε να πραγματοποιήσουμε, αφορά την τιμή ανά μονάδα επιφάνειας του εκάστοτε ακινήτου (Y house price of unit area).

1.3 Ελλιπείς τιμές και Διπλότυπες εγγραφές

Το data set αποτελείται από 414 γραμμές που αφορούν τις διαφορετικές εγγραφές και 7 στήλες που αφορούν τις μεταβλητές. Το συγκεκριμένο σύνολο δεδομένων διευκολύνει αρκετά την ανάλυση μας καθώς δεν παρουσιάζει καθόλου ελλιπείς τιμές ,όλες του εγγραφές είναι πλήρης, ενώ παράλληλα απουσιάζουν και διπλότυπες εγγραφές, κάθε εγγραφή είναι μοναδική.

1.4 Ακραίες Τιμές (outliers)

Κατά την ανάλυση πραγματοποιήθηκε έλεγχος ακραίων τιμών τόσο στις μεταβλητές εισόδου όσο και στην μεταβλητή στόχο με την χρήση της μεθόδου του ενδοτεταρτημοριακού εύρους (IQR) . Οι περισσότερες ακραίες τιμές (outliers) παρατηρήθηκαν στην μεταβλητή X3 distance to the nearest MRT station υποδηλώνοντας ότι υπάρχουν 35 κατοικίες που βρίσκονται σε μεγαλύτερη απόσταση από σταθμούς του μετρό από ότι τα υπόλοιπα δεδομένα. Γενικά παρατηρούμε ότι το μεγαλύτερο ποσοστό κατοικιών στην συγκεκριμένη περιοχή βρίσκονται συγκεντρωμένες γύρω από σταθμούς του μετρό ενώ ένα πολύ μικρός μέρος (35 κατοικίες) εμφανίζει μεγαλύτερη απόσταση. Επίσης ακραίες τιμές παρατηρήθηκαν και στις μεταβλητές X5 Latitude (8) και X6 Longitude (35), υποδηλώνοντας ότι το data set περιλαμβάνει και κατοικίες οι οποίες είναι πιο απομακρυσμένες και ξεφεύγουν από τα όρια της κυρίας οικιστικής περιοχής, ωστόσο οι κατοικίες αυτές είναι λίγες σε σχέση με τα σύνολο δεδομένων.

Όσον αφορά την μεταβλητή στόχο παρατηρήθηκαν ελάχιστες ακραίες τιμές (3), γεγονός που σηματοδοτεί ότι οι τιμές των σπιτιών ακολουθούν γενικά μια ομαλή κατανομή και δεν παρουσιάζονται πολύ χαμηλές ή αντίστοιχα πολύ υψηλές τιμές.

Πίνακας 1: Συγκεντρωτικός αριθμός ακραίων τιμών ανά μεταβλητή

Μεταβλητές	**Ακραίες Τιμές**
X1	0
X2	0
X3	37
X4	0
X5	8
X6	35
Y	3

1.5 Βασικά περιγραφικά στατιστικά για τις μεταβλητές.

Πίνακας 2: Περιγραφικά Χαρακτηριστικά

	count	**mean**	**std**	**min**	**25%**	**50%**	**75%**	**max**
X1	414	2013,15	0,28	2012,67	2012,92	2013,17	2013,42	2013,58
X2	414	17,71	11,39	0	9,02	16,1	28,15	43,8
X3	414	1083,89	1262,11	23,38	289,32	492,23	1454,28	6488,02
X4	414	4,09	2,95	0	1	4	6	10
X5	414	24,97	0,01	24,93	24,96	24,97	24,98	25,01
X6	414	121,53	0,02	121,47	121,53	121,54	121,54	121,57
Y	414	37,98	13,61	7,6	27,7	38,45	46,6	117,5

Στο παραπάνω πίνακα φαίνονται τα βασικά περιγραφικά στατιστικά για κάθε μεταβλητή.

Για την μεταβλητή εισόδου X1 (transaction date) που αφορά την ημερομηνία κατά την οποία πραγματοποιήθηκε η αγοροπωλησία παρατηρούμε ότι όλες οι κατοικίες που συμμετείχαν στην έρευνα αγοράστηκαν σε ένα διάστημα 11 μηνών (αφού min 2012.67 και max 2013.58). Η τυπική απόκλιση της μεταβλητής ανέρχεται σε 0.28 μονάδες το οποίο αντιστοιχεί σε 3.3 μήνες περίπου, αυτό σημαίνει ότι υπάρχει ομοιομορφία των συναλλαγών όσον αφορά την ημερομηνία που πραγματοποιήθηκαν και σε συνδυασμό και με το μικρό εύρος είναι εύκολα αντιληπτό να παρατηρηθεί ότι οι συναλλαγές πραγματοποιήθηκαν σε κοντινές χρονικές περιόδους κάτι τέτοιο εξυπηρετεί αρκετά την ανάλυση μας καθώς οι τιμές είναι πιο απίθανο να επηρεαστούν από εξωτερικές οικονομικές μεταβολές όπως ο πληθωρισμός κτλ.

Για την μεταβλητή εισόδου X2 (house age) παρατηρούμε ότι με μέση ηλικία τα 17.7 έτη και διάμεσο τα 16.1 έτη, το δείγμα αποτελείται κυρίως από νέα ως προς την κατασκευή σπίτια. Το ίδιο μπορούμε να παρατηρήσουμε και από την ελάχιστή τιμή (min=0) και την μεγίστη τιμή (max=0) καθώς βλέπουμε ένα σχετικά μικρό εύρος τιμών όσον αφορά την ηλικία τους, συνεπώς η περιοχή δεν φαίνεται να έχει πολύ παλαιά σπίτια.

Όσον αφορά την μεταβλητή X3, διακρίνεται ένα αρκετά μεγάλο εύρος τιμών (min=23.38 max=6488.02) , υπάρχουν δηλαδή ακίνητα που βρίσκονται πολύ κοντά στο μετρό και αλλά με πολύ μεγάλές αποστάσεις από αυτό. Οι 37 ακραίες τιμές που εντοπίστηκαν αφορούν ακριβώς αυτά τα απομακρυσμένα ακίνητα. Παράλληλα με τυπική απόκλιση 1262.11 και μέση τιμή 10083.89 φανερώνεται μια αρκετά μεγάλη ανομοιογένεια στο δείγμα , με τις κατοικίες να μην είναι συγκεντρωμένες όσον αφορά τις αποστάσεις από μετρό επηρεάζοντας έτσι την εμπορική τους αξία.

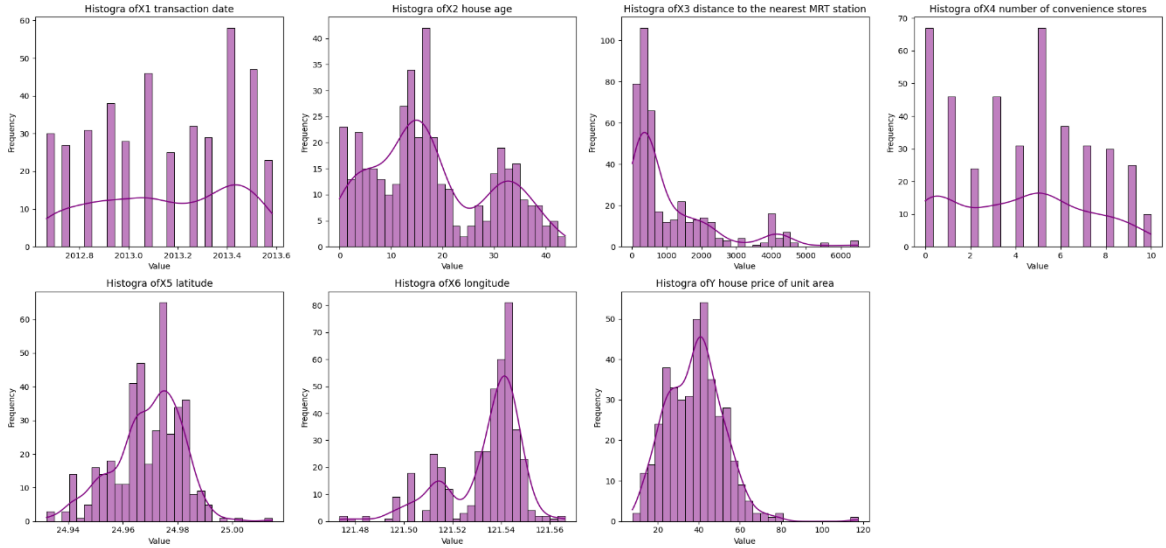
Η μεταβλητή X4 παρουσιάζει μέση τιμή 4.09 και διάμεσο 4, υποδηλώνοντας ότι το δείγμα προέρχεται από μια όχι τόσο οικιστική περιοχή, καθώς φαίνεται να υπάρχει η δυνατότητα πρόσβασής σε καταστήματα για την εξυπηρέτηση βασικών αναγκών.

Οι μεταβλητές X6 και X7 αναφέρονται στην γεωγραφική θέση της εκάστοτε κατοικίας και από τις πολύ μικρές τυπικές αποκλίσεις και των μεταβλητών, 0.01 και 0.02 αντίστοιχα είναι ευδιάκριτο ότι τα περισσότερα ακίνητα είναι γεωγραφικά συγκεντρωμένα σε μια περιοχή. Ωστόσο όπως είδαμε και προηγουμένως ,μέσω των ακραίων τιμών, υπάρχουν και ακίνητα που ξεφεύγουν από τα όρια αυτής της ενδεχόμενης περιοχής.

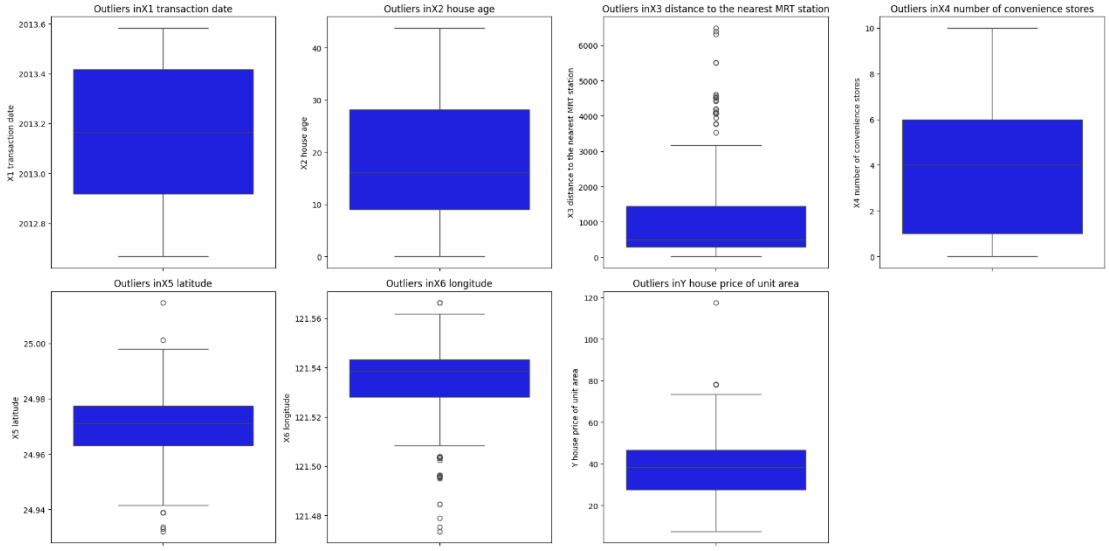
Για την μεταβλητή στόχο Y, που αναφέρεται στην τιμή ανά μονάδα επιφάνειας του ακινήτου , παρατηρούμε ότι έχει μέση τιμή 37.98 και διάμεσο 38.45 υποδηλώνοντας μια αρκετά συμμετρική κατανομή των τιμών. Επίσης η σχετικά μεγάλη τυπική απόκλιση (13.61) φανερώνει μια σημαντική διακύμανση στις τιμές γεγονός που ενισχύεται και από το μεγάλο εύρος τιμών (min=7.5 max=117.5).

1.6 Γραφήματα

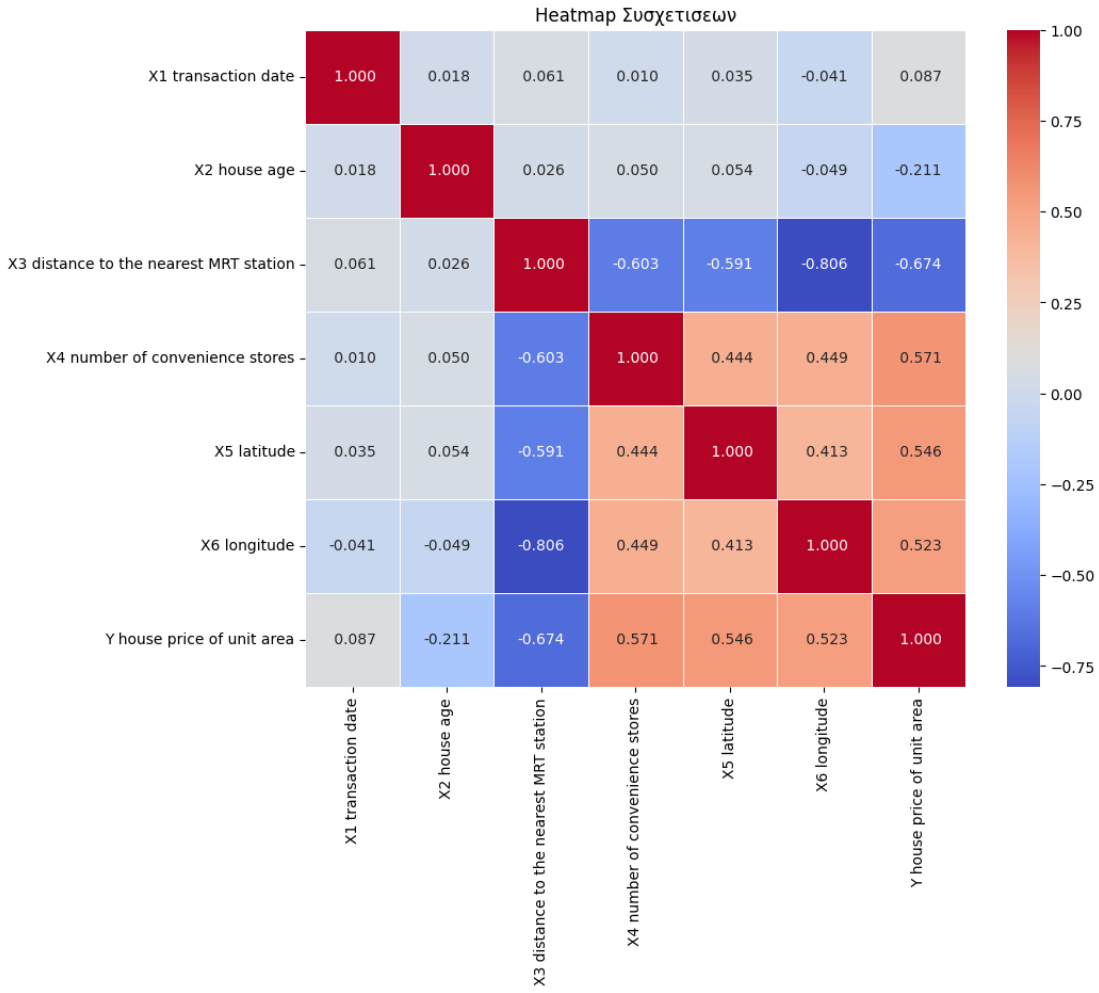
Εικόνα 1: Ιστογράμματα



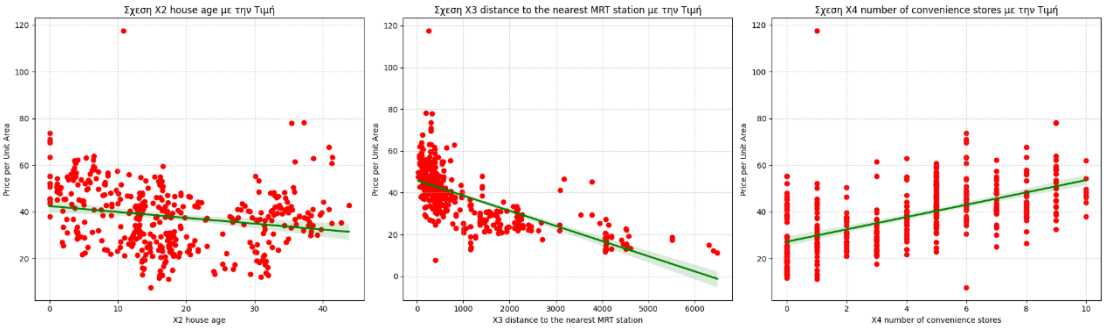
Εικόνα 2 : Boxplots



Εικόνα 3:Heatmap Συσχετίσεων



Εικόνα 4: scatter plots της μεταβλητής στόχου ως προς σημαντικά χαρακτηριστικά



Τα scatter plots δημιουργήθηκαν ως προς τα 3 σημαντικότερα, κατά την δική μας κρίση, χαρακτηριστικά και αυτά είναι η μεταβλητή X2 που αφορά την ηλικία του ακινήτου , η

μεταβλητή X3 που αφορά την απόσταση από μετρό και η μεταβλητή X4 που αφορά την ύπαρξη καταστημάτων ευκολίας στην περιοχή.

1.7 Σχολιασμός

Τόσο από το Heatmap συσχετίσεων όσο και από τα scatter plots παρατηρούμε ότι η μεταβλητή X3 (Distance to MRT) φαίνεται να σχετίζεται περισσότερο με την μεταβλητή στόχο καθώς παρουσιάζει τον υψηλότερο συντελεστή συσχέτισης με τιμή -0.67. Η συσχέτιση αυτή όπως ήταν αναμενόμενο είναι αρνητική υποδεικνύοντας ότι όσο αυξάνεται η απόσταση από το μετρό η τιμή της μεταβλητής στόχου τείνει να μικραίνει γεγονός που επιβεβαιώνει το πόσο καθοριστική είναι η απόσταση από το μετρό για τελική επιλογή ενός ακινήτου. Επίσης όσον αφορά την μεταβλητή X4 (number of convenience stores) είναι ευδιάκριτο τόσο Heatmap συσχετίσεων όσο και από τα scatter plots ότι παρουσιάζει ισχυρή θετική συσχέτιση (0.571) , φανερώνοντας ότι η ύπαρξη καταστημάτων ευκολίας στην γειτονία οδηγεί σε υψηλότερη αξία του ακινήτου.

Προεπεξεργασία

2.Προεπεξεργασία των δεδομένων

2.1 Χωρισμός δεδομένων

Προκειμένου να πραγματοποιηθεί η ανάλυση μας το σύνολο δεδομένων, το οποίο αποτελείται από 414 παρατηρήσεις διαχωρίστηκε σε ένα σύνολο εκπαίδευσης που αποτελείται από 331 παρατηρήσεις (80%) και σύνολο ελέγχου που αποτελείται από 83 παρατηρήσεις (20%).

2.2 Τυποποίηση

Προκειμένου να αναλύσουμε και να εξάγουμε συμπεράσματα για το σύνολο δεδομένων ‘Real Estate Valuation’ απαιτείται πρώτα να προβούμε στην διαδικασία της τυποποίησης (standardization). Η πρακτική αυτή κρίνεται απαραίτητη καθώς οι μεταβλητές έχουν τελείως διαφορετικές κλίμακες , Το γεγονός αυτό ελλοχεύει τον κίνδυνο μεταβλητές που παρουσιάζουν μεγάλα νούμερα ,λόγω της φύσης τους, όπως η απόσταση από το μέτρο, να τους αποδοθεί μεγαλύτερη βαρύτητα σε σχέση με μεταβλητές που έχουν μικρότερο εύρος τιμών ,όπως είναι η ύπαρξη καταστημάτων σε μια περιοχή. Έτσι λοιπόν προκειμένου να αποφευχθούν τέτοια προβλήματα και να είναι τα μοντέλα μας όσο το δυνατόν πιο αμερόληπτα θα αξιοποιήσουμε το StandarScaler της βιβλιοθήκης Scikit-learn για να φέρουμε όλες τις μεταβλητές στην ίδια κλίμακα.

2.3 Κατηγορικές μεταβλητές

Στο συγκεκριμένο σύνολο δεδομένων όλες οι μεταβλητές είναι αριθμητικές (ηλικία, απόσταση από μετρό, γεωγραφικές συντεταγμένες κτλ), επομένως δεν χρειάζεται να πραγματοποιηθεί κωδικοποίησή των δεδομένων.

2.4 Προπεξεργασία και data leakage

Η προεπεξεργασία των δεδομένων θα πρέπει αποκλειστικά να γίνεται μόνο με βάση το training set προκειμένου να αποφευχθεί το data leakage. Στόχος μας είναι να δημιουργηθεί ένα κατάλληλο μοντέλο το οποίο με βάση το σύνολο εκπαίδευσης να μπορεί λαμβάνοντας νέα δεδομένα να κάνει μια όσο το δυνατόν πιο ακριβή πρόβλεψη αν ωστόσο η προεπεξεργασια γίνει σε ολόκληρο το σύνολο δεδομένων τότε το μοντέλο μας δεν θα θεωρείται αξιόπιστο, καθώς οι πληροφορίες από το test set που υποτίθεται είναι άγνωστες θα γνωστοποιηθούν κατά την διάρκεια της προεπεξεργασίας με απότοκο το μοντέλο να μπορεί να προβλέπει με μεγάλη ακρίβεια τις τιμές του training set, αλλά θα είναι ανεπαρκές όσον αφορά πραγματικές προβλέψεις. Το μοντέλο λοιπόν εξαιτίας του data leakage θα τα πηγαίνει πολύ καλά όσον αφορά το κομμάτι των δοκιμών αλλά σε πραγματικά δεδομένα θα σημειώνει αποτυχία.

Μοντέλα και μετρικές αξιολόγησης

3. Δημιουργία Baseline Μοντέλων

3.1 Υλοποίηση και αξιολόγηση αλγορίθμων παλινδρόμησης

Σε αυτό το στάδιο υλοποιήθηκαν και αξιολογήθηκαν 4 διαφορετικοί αλγόριθμοι παλινδρόμησης με σκοπό την πρόβλεψη της τιμής των ακινήτων. Οι αλγόριθμοι που επιλέχθηκαν είναι οι εξής:

- Linear Regression
- Decision Tree Regressor
- Random Forest Regressor
- Gradient Boosting Regressor

Η εκπαίδευση όλων των μοντέλων έγινε με αρχικές/default τιμές χρησιμοποιώντας τις προεπιλεγμένες ρυθμίσεις των βιβλιοθηκών προκείμενου να πραγματοποιηθεί αντικειμενική αξιολόγηση της αρχικής απόδοσης κάθε αλγορίθμου.

Προκειμένου να αξιολογηθεί η ακρίβεια κάθε μοντέλου υπολογίστηκαν οι εξής μετρικές:

- MAE (mean absolute error): Το μέσο απόλυτο σφάλμα των προβλέψεων
- MSE (mean squared error): Το μέσο τετραγωνικό σφάλμα
- RMSE (root mean squared error): Η τετραγωνική ρίζα του MSE
- R^2: Ο συντελεστής προσδιορισμού που δείχνει το ποσοστό της διακύμανσης των τιμών που μπορούν να ερμηνευτούν από το μοντέλο.

3.2 και 3.3 Υπολογισμός μετρικών

Ο παρακάτω πίνακας περιέχει τις μετρικές για όλους τους αλγόριθμους που υλοποιήσαμε.

Πίνακας 3 : Μετρικές

Model	**MAE**	**MSE**	**RMSE**	R^2
Linear Regression	5.305	53.506	7.315	0.681
Decision Tree Regressor	5.931	66.471	8.153	0.604
Random Forest Regressor	3.964	32.557	5.706	0.806
Gradient Boosting Regressor	3.904	34.156	5.844	0.796

3.4 Σχολιασμός και συμπεράσματα

Από τον παραπάνω πίνακα μπορούμε να διακρίνουμε ότι τα μοντέλα Random Forest Regressor και Gradient Boosting Regressor αποδίδουν καλύτερα, καθώς τιμή του συντελεστή προσδιορισμού R^2 είναι υψηλότερη για τα δύο αυτά μοντέλα, 0.806 και 0.796 αντίστοιχα. Ο συντελεστής προσδιορισμού είναι ένα στατιστικό μέτρο που δείχνει το ποσοστό της διακύμανσης της εξαρτημένης μεταβλητής που εξηγείται από το μοντέλο. Οι υψηλές τιμές του συντελεστή προσδιορισμού για τα δυο αυτά μοντέλα υποδηλώνουν καλύτερη προσαρμογή του εκάστοτε μοντέλου στα δεδομένα. Παράλληλα τόσο το Random Forest Regressor όσο και το Gradient Boosting Regressor παρουσιάζουν χαμηλές τιμές στο RMSE , 5.706 και 5.844 αντίστοιχα σε σχέση με τα υπόλοιπα μοντέλα. Το RMSE αντιπροσωπεύει την μέση απόκλιση των προβλέψεων, δηλαδή την τυπική απόσταση μεταξύ των πραγματικών τιμών και των τιμών που προβλέπει το μοντέλο, συνεπώς όσο μικρότερη τιμή έχει αυτή η μετρική τόσο καλύτερη απόδοση έχει ένα μοντέλο, δηλαδή προσεγγίζει καλύτερα τα πραγματικά δεδομένα.

4. Διασταυρούμενη επικύρωση

4.1 και 4.2 Εφαρμογή k-fold cross validation και σύγκριση επιδόσεων

Σε αυτό το στάδιο, η αξιολόγηση των μοντέλων επεκτάθηκε πέρα από το απλό split (train/test) χρησιμοποιώντας τη μέθοδο της k-fold cross validation με k=5. Το σύνολο δεδομένων χωρίστηκε λοιπόν σε 5 ίσα τμήματα . Το μοντέλο εκπαιδεύτηκε 5 διαφορετικές φορές χρησιμοποιώντας κάθε φορά ένα διαφορετικό τμήμα ως test set και τα υπόλοιπα 4

τμήματα ως training set. Ενώ παράλληλα υπολογίστηκαν και οι μέσες τιμές και οι τυπικές αποκλίσεις των μετρικών.

Πίνακας 4: Μέση τιμή και τυπική απόκλιση μετρικών

Model	**R2 (Mean)**	**R2 (Std)**	**MAE (Mean)**	**MAE (Std)**	**RMSE (Mean)**	**RMSE (Std)**	**MSE (Mean)**	**MSE (Std)**
Linear Regression	0,539554	0,08664	6,4448772	0,432265	9,179201505	1,418848	86,27087	28,30789
Decision Tree	0,301316	0,449861	6,5997716	1,565244	10,75878779	3,193749	125,95155	76,88609
Random Forest	0,630613	0,123842	5,1709268	0,728059	8,138351923	1,738046	69,253576	29,17561
Gradient Boosting	0,63544	0,101241	5,2418387	0,516647	8,12933637	1,650621	68,81066	28,48718

Από τον πίνακα παρατηρούμε ότι τα μοντέλα Random Forest και Gradient Boosting εξακολουθούν να παρουσιάζουν τις καλύτερες αποδόσεις με R^2(mean)=0.630 και R^2 (mean)=0.635 αντίστοιχα, ερμηνεύοντας το μεγαλύτερο ποσοστό της διακύμανσης των τιμών των ακινήτων .Οι τιμές αυτές είναι μικρότερες από αυτές του απλού split και αυτό είναι κάτι το οποίο αναμέναμε, καθώς το cross validation είναι πιο αυστηρό, δεν βασίζεται τόσο στην τύχη και αντικατοπτρίζει καλύτερα την πραγματικότητα.

Το Decision Tree είναι το μοντέλο εκείνο το οποίο παρουσιάζει την μικρότερη τιμή στον συντελεστή προσδιορισμού (0,301) γεγονός που μας κάνει εμφανές την δυσκολία που μπορεί να έχει ένα πιο απλό μοντέλο να αντιληφθεί πιο πολύπλοκα δεδομένα που δεν έχουν ξεκάθαρες γραμμικές σχέσεις. Επίσης όσον αφορά την τυπική απόκλιση της συγκεκριμένης μετρικής παρατηρούμε ότι το Linear Regression παρουσιάζει την μικρότερη τιμή (0.086), γεγονός που μας δείχνει ότι ο συγκεκριμένος αλγόριθμος είναι πιο σταθερός από τα αλλά μοντέλα. Ανεξαρτήτως το τμήμα των δεδομένων που χρησιμοποιήθηκε κάθε φορά, η απόδοση του παρέμεινε σχεδόν ίδια. Η σταθερότητα ωστόσο αυτή συνοδεύεται από χαμηλότερη συνολική ακρίβεια, διότι το μοντέλο αδυνατεί να ακολουθήσει τις σύνθετες σχέσεις των μεταβλητών που εντοπίζουν επιτυχώς το Random Forest και το Gradient Boosting.

Όσον αφορά το μέσο απόλυτο σφάλμα (MAE) το Random Forest παρουσιάζει τη χαμηλότερη μέση απόκλιση τη χαμηλότερη μέση απόκλιση (5,170), ακολουθούμενο στενά από το Gradient Boosting (5.241). Το Linear Regression από την άλλη μαζί με το Decision Tree (είναι εκείνα τα μοντέλα που εμφανίζουν σημαντικά μεγαλύτερο μέσο σφάλμα (6.444, 6.599 αντίστοιχα), γεγονός που υποδεικνύει μειωμένη προβλεπτική ικανότητα. Από την άλλη

το Linear Regression εμφανίζει τη χαμηλότερη τυπική απόκλιση στο MAE (0.432), γεγονός που την καθιστά το πιο σταθερό μοντέλο, παρά τη χαμηλότερη συνολική ακρίβειά του. Ενώ Το Gradient Boosting συνδυάζει υψηλή ακρίβεια με χαμηλή τυπική απόκλιση (0.101), αποδεικνύοντας ότι είναι ένα στιβαρό μοντέλο που γενικεύει καλά σε άγνωστα δεδομένα. Το Decision Tree παρουσιάζει εξαιρετικά υψηλή τυπική απόκλιση σε όλες τις μετρικές .Αυτό υποδηλώνει έντονο φαινόμενο overfitting (υπερεκπαίδευση), όπου το μοντέλο αλλάζει δραματικά την απόδοσή του ανάλογα με το τμήμα των δεδομένων που βλέπει.

Η τυπική απόκλιση των RMSE και MSE αποκαλύπτει την ευαισθησία των μοντέλων στις ακραίες τιμές (outliers).Το Gradient Boosting διατηρεί το χαμηλότερο RMSE Std (1.650), επιβεβαιώνοντας ότι δεν κάνει απρόβλεπτα μεγάλα λάθη κατά τη διάρκεια των διαφορετικών κύκλων εκπαίδευσης. Αντίθετα, το Decision Tree με RMSE Std (3193) αποδεικνύεται το πιο επίφοβο μοντέλο για χρήση σε πραγματικές συνθήκες, λόγω της μεγάλης αβεβαιότητας στα σφάλματά του.

4.3 Cross-validation

Η διασταυρωμένη επικύρωση παρέχει πιο αξιόπιστη εκτίμηση της γενίκευσης από ένα απλό split καθώς εξαλείφει τον παράγοντα της τύχης . Με την πρακτική του ενός split η απόδοση του μοντέλου εξαρτάται άμεσα από τα δεδομένα που έτυχε να βρίσκονται στο test set, και αν το σύνολο αυτό αποτελείται από δεδομένα το οποία κρίνονται ως εύκολα να προβλεφθούν τότε το μοντέλο μας δεν είναι αξιόπιστο και όταν θα κληθεί να κάνει πρόβλεψη για πραγματικά δεδομένα δεν θα έχει πιθανότατα την ίδια ακρίβεια. Το cross validation περιορίζει αισθητά αυτών τον κίνδυνο. Επίσης μέσω του cross validation μπορούμε να υπολογίσουμε την τυπική απόκλιση των μετρικών και έτσι μπορούμε να αντιληφθούμε καλύτερα την σταθερότητα και την απόδοση ενός μοντέλου, καθώς υπάρχει περίπτωση ένα μοντέλο να έχει καλή απόδοση σε ένα split αλλά να είναι εξαιρετικά ασταθές . Η αστάθεια λοιπόν μπορεί να αποκαλυφθεί με το cross validation προσφέροντας μια μέση τιμή που ανταποκρίνεται στην πραγματική μέση συμπεριφορά του μοντέλου. Τέλος μπορεί να αποφευχθεί το φαινόμενο της υπερεκπαίδευσης και αυτό γιατί η διασταυρωμένη επικύρωση παρέχει μια πιο αυστηρή αξιολόγηση επομένως αν ένα μοντέλο έχει εκπαιδευτεί να απομνημονεύει το training set αυτό θα λάβει χαμηλότερες τιμές σε κάθε διαφορετικό κύκλο δοκιμής με αποτέλεσμα οι μέσες τιμές του να είναι εν τέλει μικρότερες και πιο ακριβείς.

Επιλογή μεταβλητών

5. Επιλογή Μεταβλητών (feature selection)

5.1 και 5.2 Εφαρμογή δυο διαφορετικών τεχνικών επιλογής μεταβλητών

Σε αυτή την ενότητα εξετάζουμε αν η επιλογή μεταβλητών, η μείωση δηλαδή των μεταβλητών εισόδου , μπορεί να βελτιώσει το μοντέλο ή να το καταστήσει πιο απλό χωρίς να χαθεί σημαντικό κομμάτι από την ακρίβεια του ή ακόμα και να βοηθήσει στην καλύτερη ερμηνεία των αποτελεσμάτων του.

Για την επιλογή μεταβλητών εφαρμόστηκε μια μέθοδος φίλτρου (filter method) η οποία συσχετίζει την μεταβλητή στόχο με τις ανεξάρτητες μεταβλητές εισόδου. Η μέθοδος αυτή αξιολογεί την στατιστική σχέση μεταξύ κάθε ανεξάρτητης μεταβλητής και της τιμής του ακινήτου. Στόχο έχει να εντοπίσει εκείνες τις μεταβλητές που έχουν ισχυρή σχέση με την μεταβλητή στόχο. Ως κριτήριο επιλογής επιλέχθηκαν οι μεταβλητές με απόλυτη τιμή συσχέτισης μεγαλύτερη από 0.4, ενώ οι μεταβλητές που επιλέχθηκαν είναι X3, X4,X5,X6.

Επίσης εφαρμόστηκε και μια ενσωματωμένη μέθοδος (embedded) και πιο συγκεκριμένα η SelectFromModel με χρήση Random Forest Regressor. Σε αυτήν την μέθοδο η επιλογή των χαρακτηριστικών γίνεται εσωτερικά κατά την διάρκεια της εκπαίδευσης του μοντέλου. Το Random Forest υπολογίζει την πόσο σημαντική είναι κάθε μεταβλητή εισόδου με βάση το πόσο βοηθά στην μείωση του σφάλματος της πρόβλεψης. Επιλέχθηκε η μέθοδος αυτή έναντι μιας μεθόδου περιτυλίγματος προκειμένου να αποφευχθεί η συνεχής επανεκπαίδευση του μοντέλου και είναι υπολογιστικά πιο αποδοτική. Ως κριτήριο επιλογής ορίστηκε η διάμεσος (median) επιλέγοντας έτσι το 50% των πιο σημαντικών μεταβλητών και οι μεταβλητές που εν τελεί επιλέχθηκαν είναι οι X2,X3,X5.

5.3 και 5.4 Σύγκριση της απόδοσης για Random Forest Regressor

Τα αποτελέσματα του κώδικα για τον αλγόριθμο Random Forest Regressor είναι :

Πίνακας 5: Σύγκριση Απόδοσης

Σύγκριση Απόδοσης (R2 score)	
Με όλα τα χαρακτηριστικά	0.8059
Με επιλεγμένα χαρακτηριστικά	0.7879

Από τα άνωθεν αποτελέσματα παρατηρούμε ότι όσον αφορά την επίδοση υπάρχει μια μικρή μείωση περίπου 1.8%. Αυτό υποδηλώνει ότι οι μεταβλητές που αφαιρέθηκαν περιείχαν πληροφορία που βοηθούσε στην ακρίβεια , ωστόσο επειδή η διαφορά είναι μικρή θεωρούμε ότι είναι αποδεκτή. Όσον αφορά το κομμάτι της απλότητας παρατηρούμε ότι το μοντέλο έγινε πιο απλό καθώς πλέον χρησιμοποιούνται 3 και όχι 6 μεταβλητές. Επίσης η ερμηνευσιμότητα του μοντέλου βελτιώθηκε, καθώς μπορούμε πλέον να εξηγήσουμε τις τιμές των ακινήτων βασιζόμενοι αποκλειστικά στους 3 σημαντικότερους παράγοντες: ηλικία σπιτιού, απόσταση από το μετρό και η γεωγραφική θέση.

Βελτιστοποίηση Υπερπαραμέτρων

6.Ρύθμιση υπερπαραμέτρων (hyperparameter tuning)

6.1 και 6.2 Επιλογή μοντέλων βελτιστοποίηση

Στο στάδιο αυτό ο σκοπός είναι να επιλεχθούν τα 2 καλύτερα μοντέλα από αυτά που μελετήσαμε παραπάνω και να επιδιώξουμε την βελτιστοποίηση τους προκειμένου να επιτύχουμε όσο το δυνατόν μεγαλύτερη προβλεπτική ακρίβεια.

Τα δυο μοντέλα λοιπόν που επιλέχθηκαν είναι το Random Forest Regressor και Gradient Boosting Regressor και εφαρμόστηκε η μέθοδος Grid Search.

6.3 Περιγραφή Χώρου Αναζήτησης Υπερπαραμέτρων

Στον κώδικα ορίστηκε ένας συγκεκριμένος χώρος αναζήτησης (Grid) για τα δύο μοντέλα, με σκοπό την εύρεση του βέλτιστου συνδυασμού που ελαχιστοποιεί το σφάλμα.

- Random Forest: Ελέγχθηκαν διαφορετικοί συνδυασμοί για τον αριθμό των δέντρων (n_estimators: 100, 200), το μέγιστο βάθος ανάπτυξης (max_depth: None, 10, 20) και τον ελάχιστο αριθμό δειγμάτων που απαιτούνται για τον διαχωρισμό ενός κόμβου (min_samples_split: 2, 5).
- Gradient Boosting: Εξετάστηκε ο αριθμός των δέντρων (n_estimators: 100, 200), ο ρυθμός μάθησης που καθορίζει τη συνεισφορά κάθε δέντρου (learning_rate: 0.01, 0.1) και το μέγιστο βάθος των δέντρων (max_depth: 3, 5).

6.4 Βέλτιστες υπερπαράμετροι και επίδοση (πριν /μετά)

Μετά την εκτέλεση του αλγορίθμου έχουμε ότι οι βέλτιστες υπερπαράμετροι είναι :

Για το Random Forest:

- ‘max_depth’: 10
- ‘min_samples_split’: 5
- ‘n_estimators’: 200

Για το Gradient Boosting:

- ‘learning_rate’: 0.1
- ‘max_depth’:3
- ‘n_estimators’:100

Ο πίνακας με την Σύγκριση απόδοσης :

Πίνακας 6: Πίνακας επίδοσης πριν-μετά

Μοντέλο	**R2**	**MAE**	**MSE**	**RMSE**
Random Forest (Πριν)	0,806	3,964	32,557	5,706
Random Forest (Μετά)	0,81341	3,858577	31,30223	5,59484
Gradient Boosting (Πριν)	0,796	3,904	34,156	5,844
Gradient Boosting (Μετά)	0,796402	3,903628	34,15556	5,844276

6.5 Σχολιασμός βελτίωσης

Όσον αφορά το Random Forest παρατηρούμε ότι υπάρχει μια οριακή βελτίωση στο R^2, από 0.806 σε 0.81341, αυξήθηκε δηλαδή κατά 0.007 , που είναι μια μικρή βελτίωση. Όσον αφορά το Gradient Boosting Δεν υπήρξε καμία βελτίωση – οι μετρικές παρέμειναν ακριβώς ίδιες. Αυτό συμβαίνει γιατί οι default υπερπαράμετροι του Gradient Boosting ήταν ήδη βέλτιστες για το συγκεκριμένο dataset, ή ο συνδυασμός που δοκίμασες δεν βρήκε καλύτερη λύση.

Η βελτίωση είναι οριακή και για τα δύο μοντέλα. Στην περίπτωση του Gradient Boosting, δεν υπήρξε καμία βελτίωση. Αυτό δείχνει ότι τα default μοντέλα ήταν ήδη καλά ρυθμισμένα για το συγκεκριμένο dataset, και η ρύθμιση υπερπαραμέτρων δεν προσέφερε ουσιαστικό όφελος.

Για το Gradient Boosting, οι βέλτιστες υπερπαράμετροι που βρέθηκαν από το Grid Search (learning_rate=0.1, max_depth=3, n_estimators=100) ταυτίζονται με τις default τιμές του μοντέλου ή δίνουν πανομοιότυπη απόδοση στο test set. Αυτό υποδηλώνει ότι οι προεπιλεγμένες παράμετροι ήταν ήδη βέλτιστες για το συγκεκριμένο πρόβλημα.

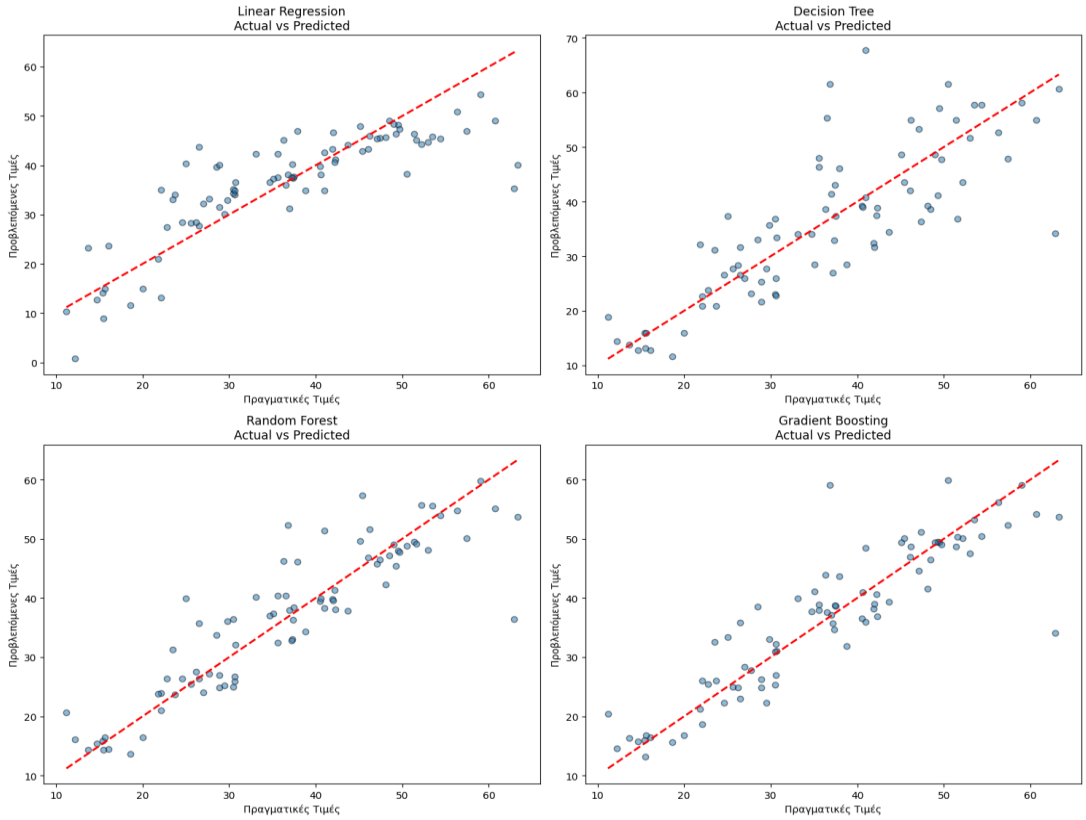
7. Ανάλυση Σφαλμάτων και διαγνωστικοί έλεγχοι

7.1 Δημιουργία διαγραμμάτων πραγματικών έναντι προβλεπόμενων τιμών

Σε αυτό το κομμάτι της εργασίας στόχος μας είναι να αναλύσουμε τα σφάλματα και να πραγματοποιήσουμε διαγνωστικούς ελέγχους.

Παρακάτω φαίνεται το διάγραμμα πραγματικών έναντι προβλεπόμενων τιμών για τα 4 διαφορετικά μοντέλα με τα οποία έχουμε ασχοληθεί.

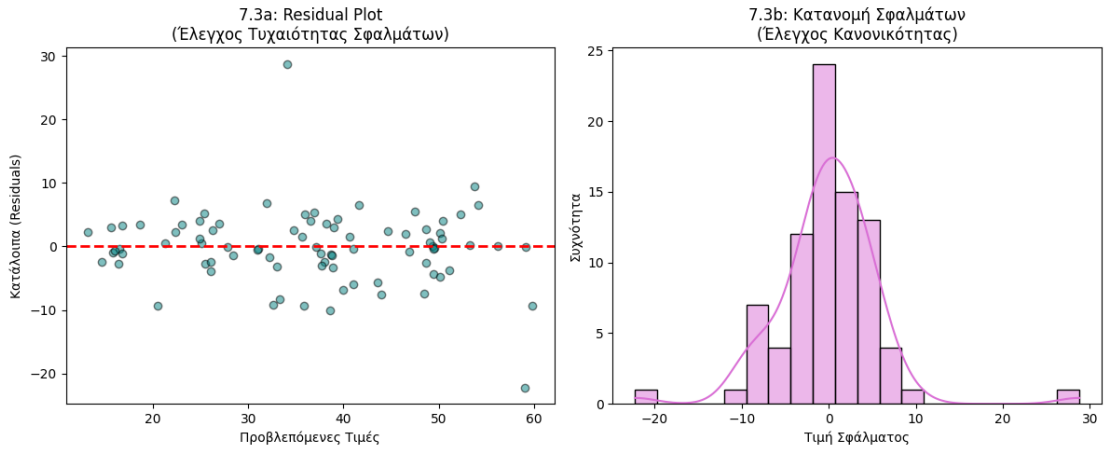
Εικόνα 5: Διάγραμμα πραγματικών έναντι προβλεπόμενων τιμών



7.2 και 7.3 Μελέτη καταλοίπων

Το μοντέλο που επιλέχθηκε ως το καλύτερο είναι το Gradient Boosting και αυτό γιατί παρότι το Random Forest είχε ελαφρώς υψηλότερο συντελεστή προσδιορισμού το Gradient Boosting έχει την ικανότητα να ελαχιστοποιεί τα σφάλματα. Το Gradient Boosting λοιπόν είναι το μοντέλο που αναδείχθηκε ως το βέλτιστο μοντέλο μέσω της διαδικασίας του Cross Validation στο Grid search. Παρακάτω ακολουθεί το residual plot και το histogram plot των residuals του Gradient Boosting .

Εικόνα 6: Residual plot and Histogram plot



7.4 Σχολιασμός

Συστηματικά Σφάλματα : Παρατηρούμε στο residual plot ότι τα κατάλοιπα είναι διάσπαρτα γύρω από τον οριζόντιο άξονα χωρίς ωστόσο να σχηματίζουν κάποιο συγκεκριμένο γεωμετρικό μοτίβο, το μοντέλο λοιπόν δεν φαίνεται να παρουσιάζει συστηματικά σφάλματα. Από το ιστόγραμμα παρατηρούμε ότι η κατανομή των σφάλματων προσεγγίζει την κανονική κατανομή , γεγονός που υποδηλώνει ότι το μοντέλο μπορεί να γενικευτεί ,με την πλειοψηφία των σφαλμάτων να συγκεντρώνονται γύρω από το μηδέν .

Μη γραμμικότητα: Η τυχαία κατανομή των καταλοίπων επίσης επιβεβαιώνει ότι οι μη γραμμικές σχέσεις των μεταβλητών έχουν αποτυπωθεί από το μοντέλο;

Ακραίες παρατηρήσεις : Παρατηρούμε επίσης ότι υπάρχουν λίγες παρατηρήσεις με σφάλμα που θα μπορούσαν να χαρακτηριστούν ως ακραία τιμή, καθώς απέχουν σημαντικά από το μηδέν . Οι τιμές αυτές είναι οι περιπτώσεις στις οποίες το μοντέλο απέτυχε να κάνει μια ικανοποιητική πρόβλεψη.

7.5 Παρατηρήσεις με μεγάλο σφάλμα

Στον παρακάτω πίνακα παρουσιάζονται οι τρεις παρατηρήσεις με το μεγαλύτερο σφάλμα :

Πίνακας 7: Παρατηρήσεις με μεγάλο σφάλμα

Παρατήρηση	Πραγματική Τιμή	Πρόβλεψη	Απόλυτο Σφάλμα
14	62.900	34.105	28.795
71	36.800	59.053	22.253
25	28.500	38.567	10.067

Στο παρατήρηση 14 βλέπουμε ότι το μοντέλο υποτίμησε πάρα πολύ την αξία του ακινήτου, καθώς παρατηρούμε μια διαφορά της τάξης των 30 μονάδων σχεδόν. Η τιμή του ακινήτου μπορεί να δικαιολογείται από μεταβλητές που δεν υπήρχαν ως είσοδοι στο σύνολο δεδομένων μας, όπως η ανακαίνιση του ή η προνομιακή του θέση σε περιοχή που έχει κοντά σχολεία επομένως εξυπηρετεί πιο εύκολα οικογένειες με παιδιά.

Στην παρατήρηση 71 η πραγματική τιμή είναι 36.800 ενώ η πρόβλεψη είναι 59.053, όπως επίσης και στην παρατήρηση 25 όπου η πραγματική τιμή είναι 28.500 ενώ η πρόβλεψη είναι 38.567. Το μοντέλο μας σε αυτές τις δύο περιπτώσεις φαίνεται να υπερεκτίμησε την αξία του ακινήτου. Η χαμηλότερη τιμή μπορεί να οφείλεται σε κακή κατάσταση του ακινήτου ή ακόμα και σε μεγάλη οικονομική ανάγκη των ιδιοκτήτων, οπότε θα μπορούσαν να προτιμήσουν μια γρήγορη και όχι τόσο συμφέρουσα οικονομική συναλλαγή από ότι μια που θα λάμβανε περισσότερο χρόνο.

Ερμηνευσιμότητα και SHAP analysis

8. Ερμηνευσιμότητα Μοντέλου

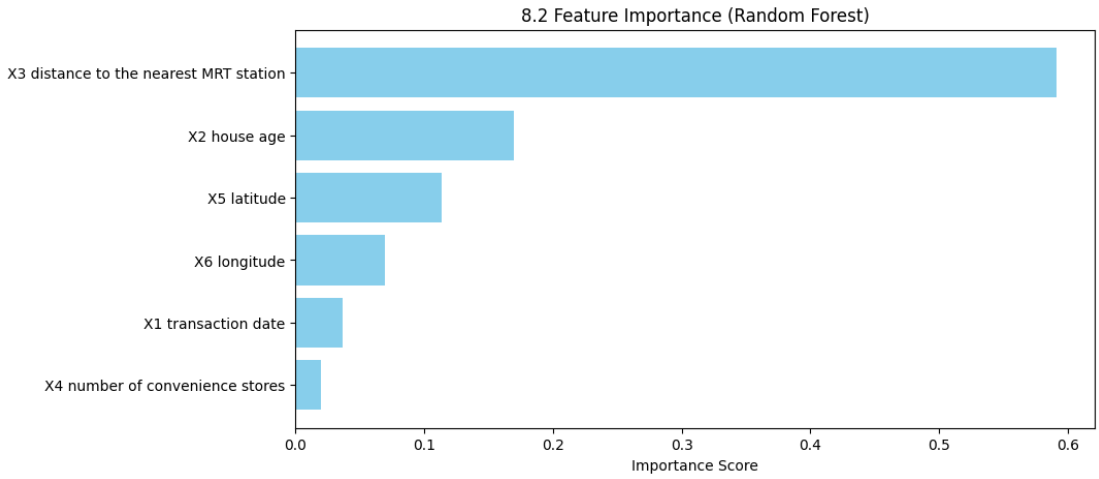
8.1 Σημασία Συντελεστών σε ένα γραμμικό μοντέλο

Στα γραμμικά μοντέλα η ερμηνεία είναι άμεση και γίνεται μέσω των συντελεστών, κάθε συντελεστής δείχνει πόσο αλλάζει η μέση τιμή του ακινήτου όταν η αντίστοιχη μεταβλητή αυξάνεται ή μειώνεται κατά μια μονάδα ενώ οι άλλες μεταβλητές παραμένουν σταθερές. Ο συντελεστής των μεταβλητών μπορεί να έχει αρνητικό η θετικό πρόσημο και αυτό καθορίζει προς τα ποια κατεύθυνση θα κινηθεί η μεταβλητή στόχος όταν αυξηθεί η μειωθεί η υπό μελέτη μεταβλητή. Η γραμμική παλινδρόμηση ωστόσο παρουσιάζει τον εξής περιορισμός : θεωρεί ότι η επίδραση είναι σταθερή ενώ στα πραγματικά δεδομένα η γραμμικότητα σπάνια ισχύει.

8.2 Παρουσίαση feature importance σε ένα ensemble μοντέλο

Σε μοντέλα όπως το Random Forest ή το Gradient Boosting η σημασία των χαρακτηριστικών υπολογίζεται με βάση το πόσο κάθε μεταβλητή συμβάλει στη μείωση του σφάλματος κατά την κατασκευή των δέντρων. Αυτό ακριβώς είναι που μας δίνει τις πρώτες πληροφορίες για το ποιες μεταβλητές παρουσιάζουν μεγαλύτερη σπουδαιότητα όσον αφορά την εξαγωγή της τιμής του εκάστοτε ακινήτου. Το feature importance αποκαλύπτει πόσο σημαντική είναι μια μεταβλητή ωστόσο ο περιορισμός είναι ότι δεν σου δίνει την κατεύθυνση που θα κινηθεί η μεταβλητή στόχος εξαιτίας της αλλαγή της τιμής κάποιας μεταβλητής. Παράλληλα όμως έχει το πλεονέκτημα ότι μπορεί να εντοπίσει την ύπαρξη αλληλεπιδράσεων ανάμεσα σε διαφορετικές μεταβλητές.

Εικόνα 7: Feature Importance (Random Forest)



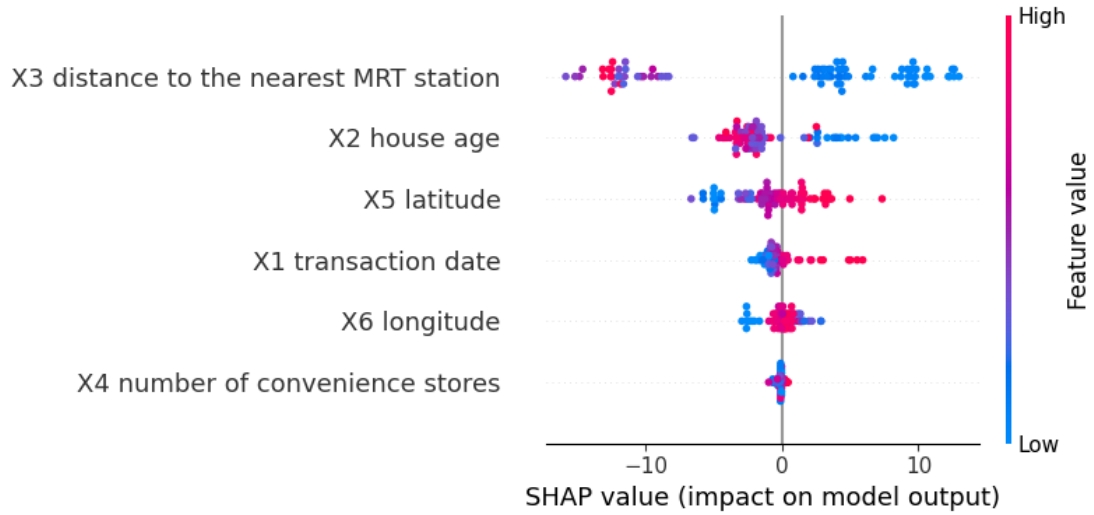
8.3 και 8.4 SHAP values

Για μια βαθύτερη και πιο αξιόπιστη ερμηνεία, χρησιμοποιήθηκαν τα SHAP values, Τα SHAP values χρησιμοποιήθηκαν προκειμένου να μετατραπεί το μοντέλο Gradient Boosting σε ένα πιο ερμηνεύσιμο μοντέλο. Η μέθοδος αυτή επιτρέπει να δούμε τόσο ποια χαρακτηριστικά είναι σημαντικά γενικά για όλα τα ακίνητα, όσο και τι επηρέασε την τιμή σε ένα συγκεκριμένο σπίτι. Σε αντίθεση με το απλό feature Importance τα SHAP values δεν μας δείχνουν απλώς ποια μεταβλητή είναι σημαντική αλλά πως επηρεάζει την τιμή αν δηλαδή την αυξάνει ή την μειώνει και κατά πόσο.

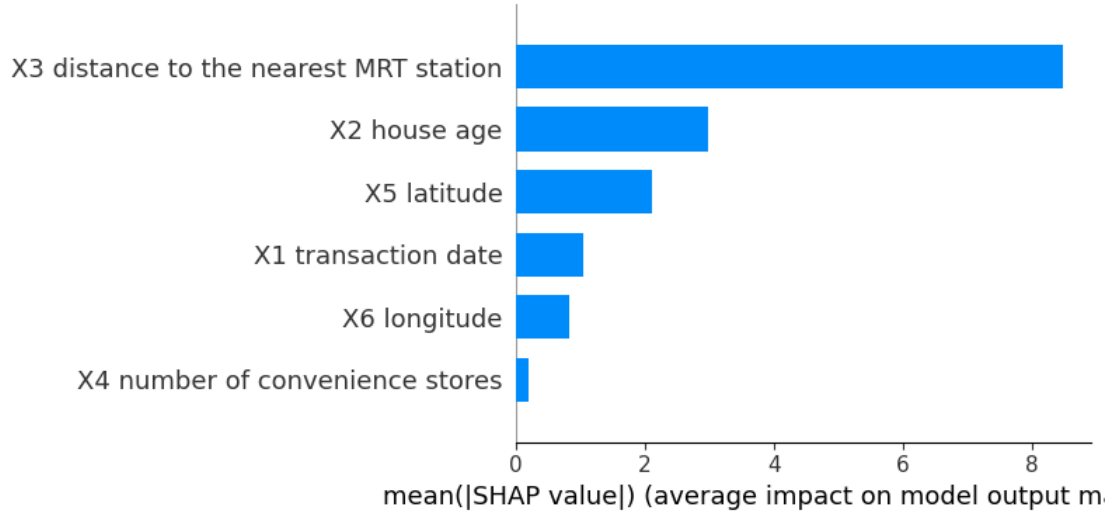
Χρησιμοποιήθηκε ο TreeExplainer της βιβλιοθήκης SHAP, ο οποίος είναι βελτιστοποιημένος για μοντέλα βασισμένα σε δέντρα απόφασης. Η ανάλυση εφαρμόστηκε

στο σύνολο δεδομένων ελέγχου (test set) προκειμένου να εξαχθούν συμπεράσματα για τη γενική συμπεριφορά του μοντέλου σε νέα, άγνωστα δεδομένα. Τα αποτελέσματα της ανάλυσης αυτής οπτικοποιούνται στις επόμενες υποενότητες (8.4 και 8.5) μέσω των διαγραμμάτων Summary Plot και Bar Plot, τα οποία αποκαλύπτουν τους κυρίαρχους παράγοντες που διαμορφώνουν τις τιμές των ακινήτων στην περιοχή μελέτης.

Εικόνα 2: SHAP summary plot



Εικόνα 3: SHAP Bar plot



8.5 Συμπεράσματα

Η ανάλυση των SHAP plots επιτρέπει την εξαγωγή σημαντικών συμπερασμάτων για τους παράγοντες που διαμορφώνουν τις τιμές των ακινήτων:

1.Βάσει του SHAP Bar plot, τα χαρακτηριστικά με τη μεγαλύτερη συνολική επίδραση στην πρόβλεψη είναι:

- X3 distance to the nearest MRT station: Αποτελεί τον κυρίαρχο παράγοντα επιρροής, καθώς παρουσιάζει τη μεγαλύτερη μέση τιμή SHAP.

- X2 house age: Ακολουθεί σε σπουδαιότητα η παλαιότητα του ακινήτου.
- X5 latitude: Η γεωγραφική θέση (γεωγραφικό πλάτος) συμπληρώνει την πρώτη τριάδα των πιο κρίσιμων μεταβλητών.
- Αντιθέτως, ο αριθμός των καταστημάτων (X4) φαίνεται να έχει την ελάχιστη συνεισφορά στη λήψη αποφάσεων του μοντέλου.

2. Από το SHAP Summary plot, παρατηρούμε την κατεύθυνση της επίδρασης κάθε μεταβλητής:

- Απόσταση από το Μετρό (X3): Παρατηρούμε ότι οι χαμηλές τιμές απόστασης (μπλε χρώμα) βρίσκονται στη δεξιά πλευρά (θετικά SHAP values), ενώ οι υψηλές τιμές (κόκκινο χρώμα) στα αριστερά. Αυτό υποδηλώνει ότι όσο πιο κοντά βρίσκεται ένα ακίνητο σε σταθμό MRT, τόσο αυξάνεται η προβλεπόμενη τιμή του.
- Ηλικία Ακινήτου (X2): Εδώ οι υψηλές τιμές ηλικίας (κόκκινο) τείνουν να βρίσκονται στην αριστερή πλευρά (αρνητικά SHAP values). Αυτό σημαίνει ότι όσο πιο παλιό είναι ένα ακίνητο, τόσο μειώνεται η αξία του.
- Γεωγραφικό Πλάτος (X5): Οι υψηλότερες τιμές (κόκκινο) συσχετίζονται με θετική επίδραση στην τιμή, υποδεικνύοντας ότι τα ακίνητα σε συγκεκριμένες βόρειες περιοχές της πόλης θεωρούνται πιο ακριβά.

Συζήτηση αποτελεσμάτων και Συμπεράσματα

9.Σύγκριση απλών και σύνθετων μοντέλων

9.1 Σύγκριση απλού ερμηνεύσιμου μοντέλου και σύνθετου

Η επιλογή μεταξύ ενός απλού μοντέλου, όπως η Γραμμική Παλινδρόμηση, και ενός σύνθετου, όπως το Random Forest, αποτελεί ένα αρκετά σημαντικό δίλλημα, καθώς στην πραγματικότητα το δίλλημα μεταφέρεται στην ανάγκη για ερμηνευσιμότητα η στην ανάγκη για ακρίβεια

Στην γραμμική παλινδρόμηση η σχέση μεταξύ των χαρακτηριστικών και της τιμής είναι άμεση και κατανοητή μέσω των συντελεστών. Είναι ιδανική για περιπτώσεις όπου η διαφάνεια είναι κρίσιμη, όπως τραπεζικά πλαίσια, καθώς επιτρέπει την εύκολη εξήγηση κάθε πρόβλεψης. Ωστόσο, όταν τα δεδομένα παρουσιάζουν μη γραμμικές σχέσεις ή περίπλοκες αλληλεπιδράσεις τότε η γραμμική παλινδρόμηση δυσκολεύεται αρκετά.

Αντιθέτως, το Random Forest είναι ένα ensemble μοντέλο που υπερέχει σε προβλεπτική ισχύ. Μπορεί να συλλάβει σύνθετα μοτίβα που μια απλή εξίσωση θα αγνοούσε, προσφέροντας συνήθως υψηλότερο τιμή στον συντελεστή προσδιορισμού και χαμηλότερα σφάλματα. Ωστόσο το Random Forest εξαιτίας ακριβώς της πολυπλοκότητας του είναι δύσκολο να εξηγηθεί διαισθητικά αν δεν χρησιμοποιηθούν εξειδικευμένα εργαλεία όπως τα SHAP values εξαιτίας των εκατοντάδων δέντρων.

9.2 και 9.3 Σχολιασμός και πρόταση για πραγματική εφαρμογή

Το δίλλημα ερμηνευσιμότητα εναντίον προβλεπτική ακρίβεια είναι ένα από τα σημαντικότερα διλλήματα που αφορούν την μηχανική μάθηση. Η ερμηνευσιμότητα αφορά την ανάγκη να καταλάβει ο ανθρώπινος νους τις αποφάσεις της ‘μηχανής’ όποτε μιλάμε για πιο απλά μοντέλα όπως είναι η γραμμική παλινδρόμηση όπου είναι πολύ πιο εύκολο να κατανοήσεις τις αποφάσεις του αλγορίθμου. Ωστόσο όταν επενδύεις στην ερμηνευσιμότητα πολύ συχνά υστερείς στο κομμάτι της ακρίβειας ειδικά όταν οι σχέσεις μεταξύ των μεταβλητών δεν παρουσιάζουν γραμμικότητα.

Από την άλλη πλευρά η προβλεπτική ακρίβεια αναφέρεται στην ικανότητα του αλγορίθμου να μπορεί να επεξεργαστεί νέα δεδομένα. Σύνθετα μοντέλα όπως το Random Forest ή το Gradient Boosting εμφανίζουν πολύ καλα ποσοστά προβλεπτικής ακρίβειας ωστόσο η εσωτερική λειτουργία τους δεν είναι τόσο εύκολα κατανοητή. Η επιλογή ωστόσο σε κάθε περίπτωση εξαρτάται από την εφαρμογή και από το σε τι ακριβώς δίνεται προτεραιότητα.

Η επιλογή ενός μοντέλου για πραγματική εφαρμογή πέρα από τα πλαίσια που ορίζει μια εργασία, απαιτεί να οριστεί αρχικά η προτεραιότητα που δίνεται, αν αυτή αφορά την ανάγκη για πιο ακριβή αποτελέσματα ή για καλύτερη ερμηνευσιμότητα. Ωστόσο επειδή τα πραγματικά δεδομένα σπανία είναι γραμμικά και οι σχέσεις είναι πολύ πιο περίπλοκες στον πραγματικό κόσμο, η πιο ασφαλής επιλογή είναι η εφαρμογή πιο σύνθετων μοντέλων που θα παρέχουν πιο ακριβή αποτελέσματα και καλύτερη γενίκευση με την χρήση παράλληλα εργαλείων όπως τα SHAP values που βοηθούν στην γεφύρωση του χάσματος ανάμεσα στην απόδοση και στην κατανόηση .

10. Αναπαραγωγιμότητα και πειραματικός σχεδιασμός

10.1 Εξασφάλιση αναπαραγωγιμότητας

Προκειμένου να εξασφαλιστεί η αναπαραγωγιμότητα των πειραμάτων ορίστηκε σταθερό random seed (random_state=42) σε όλες τις διαδικασίες οι οποίες περιλάμβαναν τυχαιότητα (διαχωρισμός δεδομένων, εκπαίδευση μοντέλων κτλ). Επιπλέον δημιουργήθηκε σαφές pipeline προεπεξεργασίας με τον διαχωρισμό αρχικά του train set από το test set , την τυποποίηση αποκλειστικά στα δεδομένα εκπαίδευσης διασφαλίζοντας ότι δεν θα υπάρξει data leakage , έπειτα την εκπαίδευση του μοντέλου και τέλος την πρόβλεψη. Επομένως η σειρά των βημάτων είναι καθορισμένη δεν υπάρχει data leakage και η επανεκτέλεση των βημάτων θα δώσει τα ίδια αποτελέσματα.

10.2 Πιθανοί περιορισμοί του data set

Το ‘Real estate Valuation’ είναι ένα σύνολο δεδομένων που εμφανίζει κάποιους περιορισμούς όσον αφορά την ανάλυση και την γενίκευση των αποτελεσμάτων του οι οποίοι παρατίθενται παρακάτω.

Μικρό μέγεθος : Το data set περιλαμβάνει ένα αρκετά μικρό δείγμα παρατηρήσεων (μόλις 414 εγγραφές) γεγονός που περιορίζει την ικανότητα του μοντέλου να εκπαιδευτεί σε ένα μεγαλύτερο δείγμα και να μάθει πιο πολύπλοκες σχέσεις ανάμεσα στις μεταβλητές. Επίσης

υπάρχει ο κίνδυνος ένα τόσο μικρό δείγμα να οδηγήσει σε overfitting, ειδικά σε πιο πολύπλοκα μοντέλα όπως είναι το Random Forest.

Θόρυβος: Κατά την διάρκεια της ανάλυσης μας εντοπίσαμε κάποιες ακραίες τιμές οι οποίες οδήγησαν σε αστοχίες των μοντέλων. Οι τιμές αυτές μπορεί να οφείλονται σε λάθη κατά την διάρκεια της καταγραφής των δεδομένων ή σε ιδιαίτερες περιπτώσεις που δεν αντιπροσωπεύουν την γενική εικόνα αλλά ακόμα μπορεί να οφείλονται και στην έλλειψη μεταβλητών που θα έδιναν περισσότερη πληροφορία στην κατανόηση τους.

Μεροληψία : Το σύνολο δεδομένων αναφέρεται σε μια συγκεκριμένη περιοχή της Ταϊβάν με αποτέλεσμα τα μοντέλα που έχουμε εκπαιδεύσει να έχουν μάθει πολύ καλά τους κανόνες της εκεί αγορά και να δρουν μεροληπτικά. Τα συμπεράσματα δεν μπορούν να γενικευτούν σε άλλες γεωγραφικές περιοχές που ισχύουν διαφορετικοί κανόνες στην αγορά.

Περιορισμένη γενικευσιμότητα : Οι αλγόριθμοι έχουν εκπαιδευτεί και τα αποτελέσματα τους έχουν αξιολογηθεί στα δεδομένα μιας συγκεκριμένης γεωγραφικής περιοχής σε μια συγκεκριμένη χρονική περίοδο, συνεπώς δεν μπορούμε να γνωρίζουμε αν θα αποδώσουν εξίσου καλά και σε άλλες γεωγραφικές περιοχές με διαφορετικές οικονομικές συνθήκες ή ακόμα και διαφορετικές προτιμήσεις των ανθρώπων για τα χαρακτηριστικά ενός ‘ιδανικού’ ακινήτου.

10.3 Προτάσεις

Σε μια μελλοντική εργασία η βελτίωση θα μπορούσε να επιτευχθεί με την προσθήκη επιπλέον μεταβλητών και την συλλογή περισσότερων ποιοτικών χαρακτηριστικών για τα ακίνητα όπως η ύπαρξη ή όχι σχολείων, νοσοκομείων στην περιοχή ή η τωρινή κατάσταση του σπιτιού (ανακαίνιση, επίπλωση, θέα κτλ)

Επίσης σημαντικό θα ήταν να συλλεχθούν δεδομένα από ένα μεγαλύτερο δείγμα αλλά και από όλες χρονικές περιόδους και περιοχές .